Task 4: Podrobná analýza porovnania promptov

Zhrnutie

- CO-STAR a RACE dosiahli zhodne **43/155 (27,7 %)**, RTF dosiahol **27/155 (17,4 %)**. Macro F1 z Tasku 3 sa pri všetkých troch promptoch rovná presnej accuracy.
- **43 je presne počet otázok, ktorých gold výsledok je prázdny.** Dotaz, ktorý vždy vráti nula riadkov, by tiež dosiahol 43/155. Dva „najlepšie" prompty teda dopadli rovnako ako triviálny baseline, ktorý nikdy nič nevráti.
- Každý neprázdny gold výsledok má **dva stĺpce** `[HOUSE_NUMBER, NAME]`. Všetky tri prompty obsahujú rovnaký few-shot príklad so `SELECT R.*`, ktorý vracia päť stĺpcov, takže neprázdna odpoveď sa s gold výsledkom nikdy nemôže zhodovať. Strop určil príklad v prompte, nie framework.
- So správnymi výstupnými stĺpcami dosahuje jednoduchý referenčný prekladač založený na pravidlách **152/155 (98,1 %)**. Úzkym hrdlom bol formát výstupu, nie náročnosť otázok.
- **Štatistická významnosť:** CO-STAR vs RACE bez rozdielu (p = 1). CO-STAR/RACE vs RTF: nepárový test je na hranici (Fisher p = 0,041, po Holmovej korekcii 0,12; χ^2 pre všetky tri prompty p = 0,050). Správny je však párový McNemarov test. V najpravdepodobnejšom scenári (všetky zásahy sú otázky s prázdnym gold výsledkom) vychádza **$p = 3{,}1 \cdot 10^{-5}$**. Rozdiel ostáva významný, kým RTF nemá aspoň 22 zásahov, ktoré ostatné prompty netrafili.
- Texty promptov RTF a RACE sú na **98,7 % rovnaké**, líšia sa len dvoma nadpismi sekcií. To, že RTF dosiahol o 16 bodov menej, preto najlepšie vysvetľuje **variabilita coding agenta medzi behmi**. RTF potreboval 49 krokov a 10 m 50 s, ostatné prompty 21 – 32 krokov a približne 3 – 4 minúty. Prompt framework je najmenej pravdepodobné vysvetlenie.

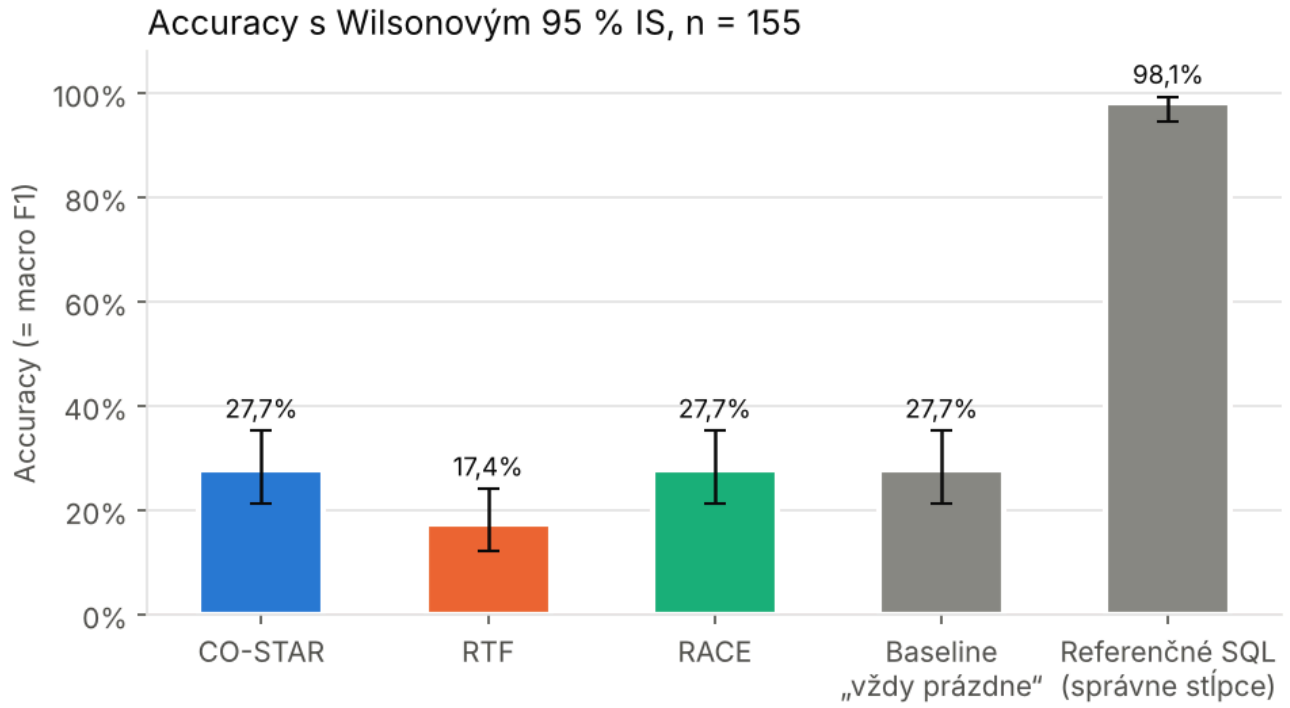
---

1. Experimentálne nastavenie a faktory

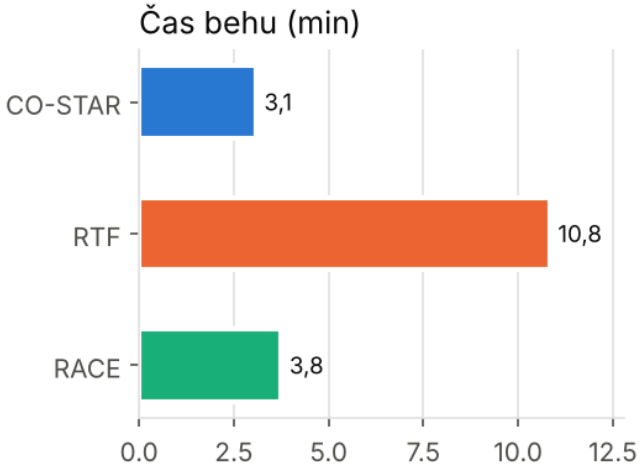
Faktor	Hodnota v Tasku 2	Menil sa?
Prompt framework	CO-STAR, RTF, RACE (Task 1)	**áno**, sledovaná premenná
Model	model, ktorý používal GitHub Copilot CLI (v metadátach session nezaznamenaný)	nie
Coding agent	GitHub Copilot CLI agent vo VS Code, nová session pre každý prompt	nie, ale je stochastický
Pracovný priečinok	iba `restaurants_dataset.csv`, `restaurants-schema.csv`	nie
Počet opakovaní	**1 beh na prompt**	–
Dataset	155 otázok v prirodzenom jazyku, gold = riadky výsledku referenčného SQL	–

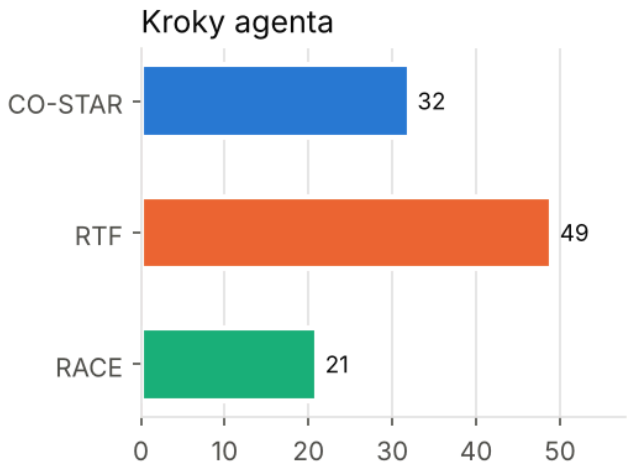
Vyhodnotenie: každý predikovaný dotaz sa spustí nad SQLite databázou zostavenou z `restaurants-db.txt`. Predikcia je správna, ak sa multimnožina jej výsledku zhoduje s gold multimnožinou (Task 2). Macro precision, recall a F1 nad riadkami výsledku pochádzajú z Tasku 3.

2. Výsledky



Prompt	Správne	Accuracy	Wilsonov 95 % IS	Macro F1	SQL chyby	Kroky agenta	Čas	s / otázka
CO-STAR	43	27,74 %	21,3 – 35,3 %	0,2774	0	32	3 m 05 s	1,19
RTF	27	17,42 %	12,3 – 24,2 %	0,1742	0	49	10 m 50 s	4,19
RACE	43	27,74 %	21,3 – 35,3 %	0,2774	0	21	3 m 45 s	1,45
Baseline „vždy prázdne“	43	27,74 %	21,3 – 35,3 %	0,2774	–	–	–	–
Referenčné SQL, správne stĺpce	152	98,06 %	94,5 – 99,3 %	–	–	–	–	–





Pozorovania:

1. CO-STAR a RACE sa nedajú rozlíšiť: rovnaký počet správnych odpovedí aj rovnaký interval spoľahlivosti.
2. RTF je približne o 10 percentuálnych bodov horší a zároveň najpomalší: 3,5× dlhší čas a 1,5 – 2,3× viac krokov. Vyššie náklady nepriniesli lepšiu presnosť.
3. Macro F1 = accuracy, pretože žiadna otázka nedostala čiastočný kredit (Task 3 našiel 0 čiastočných skóre). Dôvod vysvetľuje kapitola 4: päťstĺpcový riadok sa nikdy nemôže rovnať dvojstĺpcovému gold riadku, takže prekryv riadkov je vždy nulový. Možné boli len dva výsledky: „oba prázdne“ (F1 = 1) alebo „žiadny prekryv“ (F1 = 0).
4. Čas bol meraný iba raz na prompt, takže rozdiely v čase sa nedajú štatisticky otestovať (n = 1). Navyše zahŕňa aj réžiu agenta (čítanie súborov, písanie skriptov, opakované pokusy), nielen samotnú inferenciu modelu.

3. Je rozdiel štatisticky významný?

3.1 Nepárové testy (konzervatívne, behy sa berú ako nezávislé vzorky)

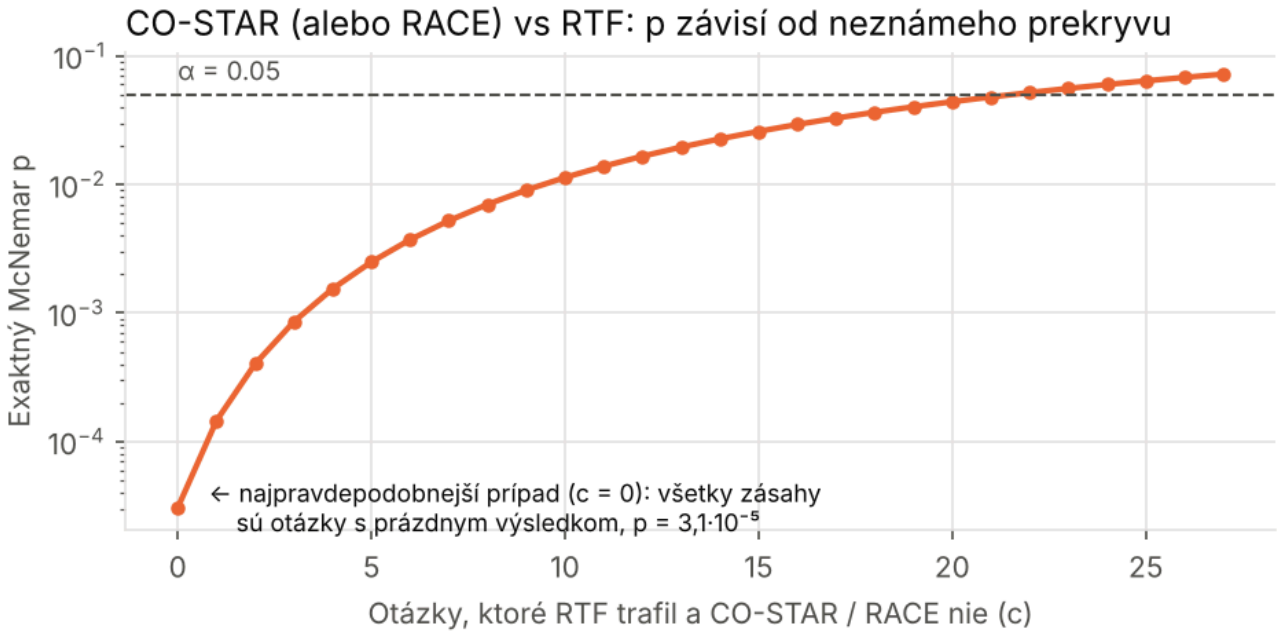
Test	Štatistika	p	p po Holmovej korekcii	Veľkosť efektu
χ^2 homogenity, 3 prompty × {správne, nesprávne}	$\chi^2 = 5{,}99$, df = 2	0,0501	–	–
Fisherov exaktný test, CO-STAR vs RTF	–	0,041	0,123	Cohenovo h = 0,25 (malý)
Fisherov exaktný test, RACE vs RTF	–	0,041	0,123	h = 0,25 (malý)
Fisherov exaktný test, CO-STAR vs RACE	–	1,000	1,000	h = 0

Po korekcii na tri porovnania nepárový pohľad **nedosahuje** významnosť na hladine $\alpha = 0{,}05$.

3.2 Párový test (správny dizajn)

Všetky prompty odpovedali na **tých istých 155 otázok**, takže výsledky sú párové. Vhodné testy sú **exaktný McNemarov test** pre každú dvojicu a **Cochranov Q test** pre všetky tri prompty naraz. Tieto testy pracujú iba s *nesúhlasnými* otázkami (jeden prompt odpovedal správne, druhý nie). Tým odstraňujú náročnosť otázok ako zdroj šumu a majú oveľa väčšiu silu.

Task 3 uložil výsledky po otázkach do `f1_per_question.csv`, ale táto analýza mala k dispozícii iba súhrnné čísla. P-hodnotu sa však dá ohraničiť. Pre CO-STAR (43) vs RTF (27) označme *c* počet otázok, ktoré RTF trafil a CO-STAR nie. Potom CO-STAR má $b = 16 + c$ exkluzívnych zásahov:



- **c = 0 (najpravdepodobnejšie, pozri kapitolu 4):** b = 16, c = 0, exaktný McNemar **$p = 3{,}1 \cdot 10^{-5}$**. Cochranovo Q = 32,0, df = 2, **$p = 1{,}1 \cdot 10^{-7}$**.
- Rozdiel ostáva významný na hladine α = 0,05 pre každé c ≤ 21. Nevýznamný by bol až vtedy, keby RTF mal aspoň 22 zásahov, ktoré CO-STAR netrafil. To by znamenalo správne zodpovedať aspoň 22 otázok s neprázdnym výsledkom, čo je s päťstĺpcovým výstupom nemožné (kapitola 4).
- CO-STAR vs RACE: ak oba trafili presne 43 otázok s prázdnym gold výsledkom, nesúhlasné páry neexistujú a p = 1.

`analysis.py` spustí presné párové testy automaticky, ak existuje súbor `../Task_3/f1_per_question.csv` (výstup ide do `paired_results.csv`).

Záver: dáta silno naznačujú, že RTF *v tomto behu* dopadol horšie ako CO-STAR a RACE a že CO-STAR a RACE dopadli rovnako. Prečo to ešte neznamená, že horší je RTF *framework*, vysvetľuje kapitola 5.

4. Prečo je presnosť taká nízka? Analýza gold dát



Vlastnosť gold dát	Hodnota
Otázky	155
Prázdny gold výsledok	**43** (27,7 %)
Neprázdny gold výsledok	112
Stĺpce v neprázdnom gold riadku	**vždy 2:** `[HOUSE_NUMBER, NAME]`
Najväčší gold výsledok	9 171 riadkov
Otázky s nesúvisiacim rušivým textom („…whether pasta belongs in a lunchbox or a flowerpot“)	41
Zjavne chybne označené otázky („What is the lifes greates illusion?“ → zoznam afganských reštaurácií)	≥ 1

Všetky tri prompty obsahujú ten istý few-shot príklad:

```
SELECT R.* FROM RESTAURANT R WHERE LOWER(R.CITY_NAME) = 'winters' AND LOWER(R.FOOD_TYPE) = 'te
a' ORDER BY R.RATING DESC LIMIT 1;
```

`R.*` vráti `(ID, NAME, FOOD_TYPE, CITY_NAME, RATING)`. Päť hodnôt sa nikdy nerovná dvom, takže **dotaz, ktorý prevezme projekciu z príkladu, môže byť správny iba vtedy, keď je gold výsledok prázdny.** Strop pre každý prompt bol 43/155. CO-STAR a RACE ho dosiahli presne.

Aby sa overilo, že obmedzením sú stĺpce a nie náročnosť otázok, `analysis.py` obsahuje malý **referenčný prekladač založený na pravidlách** (16 regex šablón). Je to diagnostický nástroj vyladený na tento dataset, nie férový súper LLM. Výsledky:

Prekladač	Správne
Referenčná logika so `SELECT L.HOUSE_NUMBER, R.NAME`	**152 / 155**
Rovnaká logika so `SELECT R.*`	42 / 155
Dotaz, ktorý vždy vráti prázdny výsledok	43 / 155

Tie isté WHERE podmienky klesnú z 98 % na 27 %, keď sa zmení iba zoznam stĺpcov v SELECT. Referenčný prekladač odhalil aj ďalšie skryté konvencie gold SQL, ktoré prompty neuvádzali:

- mesto sa filtruje cez `LOCATION.CITY_NAME` (s `RESTAURANT.CITY_NAME` by sa stratilo 7 otázok),
- „the bay area / the monterey …“ znamená `GEOGRAPHIC.REGION`,
- „rating above X“ znamená ostré `>` (s `>=` by sa stratilo 32 otázok),
- ulica sa porovnáva presnou zhodou,
- „best“ vracia všetky reštaurácie s maximálnym hodnotením vrátane remíz, nie `LIMIT 1`. Pravidlo v prompte tu odporuje gold dátam, hoci remízu má iba jedna zo 17 „best“ otázok.

5. Prečo sa prompty líšia tak, ako sa líšia

5.1 Faktor promptu: prompty sú takmer ten istý prompt

Dvojica	Textová podobnosť (difflib ratio)
RTF vs RACE	**0,987**
CO-STAR vs RTF	0,237
CO-STAR vs RACE	0,238

RTF a RACE sa líšia iba dvoma nadpismi („Translation Rules & Guidelines“ vs „Instructions“, „Format“ vs „Output requirements“). CO-STAR mení rozloženie a pridáva sekcie *Tone* a *Audience*, ale obsahuje tú istú schému, tie isté pravidlá a **ten istý príklad so** `SELECT R.*`. Nízka podobnosť je spôsobená preformulovaním, nie iným obsahom. Prakticky dostal model vo všetkých troch promptoch rovnaké informácie.

Framework teda ovplyvnil veľmi málo. Jediné rozhodnutie, na ktorom záležalo, bola projekcia vo few-shot príklade, a tá bola vo všetkých troch promptoch rovnaká. **Rozdiel 27,7 % vs 17,4 % nemôže pochádzať zo štruktúry RTF**, pretože RACE má rovnakú štruktúru aj znenie a dosiahol 27,7 %.

Doplnkové sekcie CO-STAR („deterministic“, „rule-bound“, „no creative liberties“, „automated evaluation pipeline“) môžu agenta tlačiť k doslovnému dodržaniu príkladu. Na tomto datasete to nič nezmenilo, lebo doslovné dodržanie príkladu dáva rovnaké skóre ako baseline „vždy prázdne“.

5.2 Faktor modelu: dôsledné plnenie inštrukcií a ukotvenie na príklade

Model prevzal projekciu z príkladu do každého dotazu: nula SQL chýb a zároveň žiadny zásah medzi 112 otázkami s neprázdnym výsledkom. Ide o typické **ukotvenie na few-shot príklade** (few-shot anchoring). LLM kopírujú povrchovú formu príkladov v kontexte (zoznam stĺpcov, aliasy, `LOWER()`) často vernejšie, než dodržiavajú abstraktné pravidlá. Schéma neuvádza, ktoré stĺpce má odpoveď obsahovať, a znenie otázok („give me a restaurant“, „where is…“) nenaznačuje `HOUSE_NUMBER, NAME`. Model nemal z promptu ako túto konvenciu odvodiť.

Nulová chybovosť a plné skóre CO-STAR a RACE na otázkach s prázdnym výsledkom zároveň ukazujú, že model zvládol 41 rušivých viet. Nepridal podmienky, ktoré by viedli k nesprávnym neprázdnym výsledkom.

5.3 Faktor coding agenta: najpravdepodobnejšia príčina rozdielu RTF

Úlohu neriešilo jedno volanie modelu, ale **agent** (Copilot CLI). Agent si sám volí stratégiu: prekladať otázky po jednej, napísať Python skript so šablónami, preskúmať dáta, testovať dotazy a podobne.

Prompt	Kroky	Čas	Skóre
RACE	21	3 m 45 s	43
CO-STAR	32	3 m 05 s	43
RTF	49	10 m 50 s	27

RTF a RACE mali prakticky rovnaký vstup, no RTF session potrebovala viac ako dvojnásobok krokov a takmer trojnásobný čas. Agent teda zvolil **iný postup**. Ak RTF netrafil 16 otázok s prázdnym gold výsledkom, vrátil pri nich *riadky* tam, kde gold nevracia nič. Pravdepodobné príčiny (treba overiť v `RTF_restaurants_dataset_predictions.csv`):

- voľnejšie porovnávanie, napríklad `LIKE '%…%'` alebo vynechaný filter, ktoré vráti riadky aj pre neexistujúce kombinácie typu „tea food in winters“,
- vygenerovaný skript alebo šablóna, ktorá zle sparsovala otázky s rušivým textom a stratila podmienku,
- čiastočné prepracovanie alebo opätovné generovanie počas dlhšej session.

Session agenta sú stochastické: líši sa sampling (teplota), poradie volaní nástrojov aj opakované pokusy. **Pri jednom behu na prompt sa efekt frameworku nedá oddeliť od variability session.** McNemarov test ukazuje, že sa významne líšia *tieto dva behy*. Neukazuje, že RTF framework je horší.

5.4 Ďalšie faktory

- **Gold dáta v pracovnom priečinku:** `restaurants_dataset.csv` obsahuje stĺpec `result`, takže agent mohol vidieť očakávané odpovede vrátane ich dvojstĺpcového tvaru. Zdá sa, že žiadna session ich nevyužila, ale ide o riziko úniku dát (leakage), ktoré treba spomenúť.
- **Behy za sebou:** RACE začal o 17:20, RTF o 17:31, CO-STAR o 17:48. Session boli oddelené, ale záťaž servera ani verzia modelu neboli kontrolované.
- **Šum v gold dátach:** aspoň jedna otázka je nezodpovedateľná, čo mierne znižuje dosiahnuteľný strop pre všetky prompty.

6. Ohrozenia validity

Ohrozenie	Dopad	Náprava
n = 1 beh na prompt	efekt frameworku sa mieša s variabilitou session	≥ 5 behov na prompt, priemer ± SD, mixed-effects alebo permutačný test
Model nebol zaznamenaný	výsledky nie sú reprodukovateľné	zapisovať ID modelu do metadát
Rovnaký few-shot príklad vo všetkých promptoch	frameworky sa obsahovo takmer nelíšia	meniť obsah, nielen nadpisy, alebo testovať príklad ako samostatný faktor
Strop 27,7 %	metrika merala len „nevráť nič, keď nič neexistuje“	uviesť v prompte výstupné stĺpce
Gold dáta viditeľné pre agenta	možný únik dát	dať agentovi súbor iba s otázkami
Čas zahŕňa réžiu agenta	nie je to čistý čas inferencie	logovať počty tokenov a latenciu modelu zvlášť

7. Odporúčania pre ďalšiu iteráciu

1. Do každého promptu pridať riadok *„Return exactly two columns: `L.HOUSE_NUMBER, R.NAME` (join `LOCATION` on `RESTAURANT_ID`)“* a podľa toho opraviť príklad. Podľa referenčného prekladača iba toto posunie strop z 27,7 % na približne 98 %.
2. Uviesť aj ostatné konvencie: mesto z `LOCATION`, región z `GEOGRAPHIC`, `>` pre „above“, remízy pri „best“.
3. Každý prompt spustiť **5 – 10-krát** v nových session. V rámci behu porovnávať párovým McNemarovým alebo Cochranovým Q testom a naprieč behmi permutačným testom.
4. Odstrániť stĺpec `result` zo vstupu agenta.
5. Keď sa neprázdne odpovede budú môcť zhodovať, F1 z Tasku 3 začne dávať zmysel, lebo sa objaví aj čiastočný prekryv riadkov.

8. Reprodukcia

```
cd Week_03_Prompting/Assignments/Task_4
python analysis.py          # potrebuje scipy, matplotlib
```

Výstupy: `stats_summary.json`, `figures/*.png` a `paired_results.csv`, ak existuje `../Task_3/f1_per_question.csv`. Ak sú súbory s predikciami v `../Task_2/data/OUTPUT/`, skript zároveň vypíše, koľko stĺpcov vracajú dotazy jednotlivých promptov. Tým priamo overí vysvetlenie so `SELECT R.*`.